

Data Analysis : Cancer de la prostate

N° Sciper : 260556

19 novembre 2017

Table des matières

Introduction	3
Modèle final	3
Analyse exploratoire des données	3
Sélection du modèle	4
Analyse du modèle final	6
Discussion	7
Conclusion	7
Bibliographie	8

Introduction

Ce rapport décrit la construction d'un modèle linéaire pour la variable `lpsa` (log de l'Antigène Prostatique Spécifique) d'un jeu de données provenant d'une étude par T.A. Stamey *et al* (1989) au sujet de la corrélation entre le `lpsa` et 8 autres variables, à partir de mesures prises chez 97 hommes souffrant du cancer de la prostate. L'enjeu est de déterminer si le taux de PSA dans le sang, mesure facile à prendre, est un bon indicateur de l'avancée du cancer chez un patient, ce qui semble être le cas. Les données suggèrent en effet que le `lpsa` est proportionnel au `lcavol` (log du volume de cancer).

Modèle final

Le modèle sélectionné décrit le `lpsa` comme fonction de `lcavol`, `lweight`, `svi` et d'un bruit :

$$\text{lpsa} = \beta_0 + \beta_1 \times \text{lcavol} + \beta_2 \times \text{lweight} + \beta_3 \times \text{svi} + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

Analyse exploratoire des données

Des détails sur la signification des variables sont trouvées dans Wakefield (2013) :


- **lcavol** : Log du volume de cancer (en ml).
- **lweight** : Log du poids de la prostate (en g).
- **age** : Age du patient (en années).
- **lbph** : Log de l'hypertrophie bénigne de la prostate, une condition d'élargissement de la prostate, mesurée comme surface sur une image en cm^2 .
- **svi** : Variable indicatrice 0/1 indiquant si les cellules cancéreuses ont envahies la vésicule séminale.
- **lcp** : Log de la pénétration capsulaire (en cm).
- **gleason** : Score Gleason, une mesure de l'agressivité de la tumeur, prenant valeurs entières de 2 à 10.
- **pgg45** : Pourcentage du score Gleason étant 4 ou 5.
- **lpsa** : Log de l'antigène prostatique spécifique, une concentration mesurée en ng/ml .

Tout d'abord, la fonction de densité empirique du `lpsa` (Figure 1) est plus ou moins normale, ce qui ne contredit pas l'adéquation d'un modèle linéaire.

Nous regardons ensuite les valeurs de la table de corrélation des variables. Le `lpsa` a une haute corrélation avec le `lcavol` (0.73) et le `lcp` (0.55) et cela se voit sur les Figures 2 et 3. Les deux variables importantes semblent être `lcavol` et `lcp`. Cependant, ces deux variables sont aussi corrélées (0.68), donc il se peut qu'elles donnent la même information au sujet de `lpsa`. Cela semble être le cas ; en effet, un test ANOVA pour les modèles emboîtés $\text{lpsa} \sim 1 + \text{lcavol}$ et $\text{lpsa} \sim 1 + \text{lcavol} + \text{lcp}$ suggère que le `lcp` n'est pas significatif au seuil 5% lorsque `lcavol` est déjà dans notre modèle ($p\text{-valeur} = 0.31 > 0.05$) et un test ANOVA pour les modèles emboîtés $\text{lpsa} \sim 1 + \text{lcp}$ et $\text{lpsa} \sim 1 + \text{lcp} + \text{lcavol}$ suggère que `lcavol` est significatif au seuil 5% lorsque `lcp` est déjà dans notre modèle ($p\text{-valeur} = 0.00$). Donc `lcavol` semble expliquer la même chose, et plus, que `lcp`.

Similairement, le `lpsa` a la corrélation la plus faible avec l'âge (0.17) et le `lbph` (0.18). Cependant, nous ne pouvons pas nous permettre d'écarter immédiatement la possibilité d'un modèle avec l'âge ou le `lbph` à cause de cela. En effet, plusieurs études ont montré que ces conditions peuvent influencer, de manière indépendante, le PSA chez les hommes sans cancer (Nadler RB 1995, Collins GN (1993)).

Finalement, on remarque (Figures 6) que le `lpsa` prend des ensembles de valeurs relativement différentes selon la valeur des variables discrètes `svi` (idem pour `gleason`), donc il n'est pas improbable que ces variables aient un effet significatif sur `lpsa`.



N = 97 Bandwidth = 0.3564

Figure 1 : Densité empirique du lpsa




Figure 2 : lpsa vs lcavol




Figure 3 : lpsa vs lcp

Added-Variable Plot: lcavol




Figure 4 : lcavol vs lcp




Figure 5 : Added variable plot pour lcavol




Figure 6 : lpsa vs svi

Sélection du modèle

Tout d'abord, nous commençons avec le modèle complet $\text{lpsa} \sim .$ (i.e. comprenant tous les prédicteurs). En étudiant le *summary*, on observe qu'une série de T-tests (tests de Wald) individuels au seuil 5% pour l'hypothèse nulle $H_0 : \beta_i = 0$ (β_i le coefficient associé à un prédicteur spécifique) semble indiquer que les variables explicatives significatives sont lcavol, lweight, svi et age.

Un F-test au seuil 5% entre les modèles emboîtés $\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi}$ et $\text{lpsa} \sim .$ ne permet pas de rejeter l'hypothèse nulle H_0 (mettant à zéro simultanément tous les coefficients β_i associés aux prédicteurs différents de lcavol, lweight, svi) ($p\text{-valeur} = 0.22 > 0.05$), donc le test ne va pas à l'encontre de l'adéquation du modèle plus simple.

On utilise maintenant d'autres méthode de sélection de modèle, en commençant par une sélection LASSO avec la *1-standard deviation rule* (Breiman Leo 1984) (on choisit le lambda (ligne bleue, Figure 8) ayant le modèle le plus régulier à distance de 1-déviations standard par rapport à la moyenne de la validation croisée pour le lambda optimal (en traitillé, Figure 8)).




Figure 7 : Coefficients vs L1 pénalisation




Figure 8 : 10-fold cross-validation vs log lambda

On obtient le modèle $\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi}$.

Remarquons (mais nous ne donnons pas les détails ici) que les méthodes étape par étape (*stepwise*) en sélection ascendante et descendante avec F-test comme critère de sélection mènent aussi au modèle $\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi}$. Si à partir de ce dernier modèle, on continue la sélection ascendante pour ajouter des termes d'interactions, on obtient le modèle $\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi} + \text{lweight}:\text{svi}$.

Finalement, en itérant sur les modèles avec interactions (interactions présentes uniquement avec les variables d'ordre inférieur qui les composent) à moins de 8 prédicteurs, on obtient que les meilleurs modèles (à 2 de différence) selon le BIC (*Bayesian Information Criterion*) sont :

TABLE 1: Modèles sélectionnés par BIC et modèle complet


Model	BIC	Adj.R2	PRESS	MaxVIF
$\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi}$	225.7	0.624	50.98	1.5
$\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi} + \text{svi}:\text{lweight}$	226.6	0.634	50.32	124.7
$\text{lpsa} \sim 1 + \text{lcavol} + \text{lweight} + \text{svi} + \text{lweight}:\text{lcavol}$	227.2	0.632	50.37	98.6
$\text{lpsa} \sim .$	248.5	0.635	53.14	3.5

Nous décidons de choisir le modèle le plus simple. En effet, les termes d'interactions $\text{svi}:\text{lweight}$ et $\text{lweight}:\text{lcavol}$ sont difficiles à interpréter. Le poids de la prostate influence-t-il vraiment des variables liées au cancer et inversement ? De plus, il n'y a pas de grandes différences de performance en matière de prédiction si l'on regarde la PRESS statistique (*leave-one-out residuals*). Aussi, rajouter ces termes d'interactions ajoute de la collinéarité au problème, ce qui est indésirable.

Analyse du modèle final

On remarque (Table 1) que le modèle choisi possède une meilleure PRESS statistique que le modèle complet, suggérant que le modèle complet est surajusté aux données. Ceci est confirmé par la médiane d'une 10-validation croisée répétée 100 fois entre le modèle choisi ($cv = 50.99$) et le modèle complet ($cv = 53.31$) (où on a dû retirer l'observation 37, seule donnée de patient avec un score Gleason 8, créant ainsi un levier de valeur 1).

On regarde alors les graphiques résiduels du modèle $lpsa \sim 1 + lcavol + lweight + svi$ pour déterminer si les hypothèses de la régression linéaire ne sont pas nettement violées et donc de déterminer si elles sont de bonnes approximations de la réalité



On ne distingue pas de structure dans le graphique Residuals vs Fitted values, ne contredisant pas l'hypothèse de linéarité. Idem, pour le nuage de points Standardized Residuals vs Fitted values et l'hypothèse d'homogénéité de la variance. Le Normal QQ-Plot des quantiles empiriques des Standardized Residuals contre les quantiles théoriques d'une loi normale sont tous compris dans le 95%-intervalle de confiance (dérivé de la distribution Beta d'une statistique d'ordre) et sont assez bien alignés sur la droite $y = x$, ce qui ne va pas à l'encontre de l'hypothèse de normalité. Dans notre cas, nous n'avons pas de prédicteurs temporels, donc il est difficile de tester l'hypothèse d'indépendance des erreurs ε_i . Finalement, on remarque que les observations 38 et 39

possèdent une grande distance de Cook (où la ligne rouge désigne l’heuristique $C_j > 8/(n - 2p)$). Après vérification, il ne s’agit pas de leviers, mais de valeurs aberrantes. Cependant, rien ne semble d’anormal pour ces deux observations (elles n’ont pas nécessairement des valeurs trop extrêmes), donc nous ne les enlèverons pas.

Discussion

Nos méthodes de sélection nous ont amené à choisir un modèle sans interactions : $\text{lpsa} = \beta_0 + \beta_1 \times \text{lcavol} + \beta_2 \times \text{lweight} + \beta_3 \times \text{svi} + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2)$. En choisissant ce modèle, nous supposons que les interactions entre nos 8 variables indépendantes initiales n’influencent pas de manière significative le lpsa.

En regardant notre modèle en soi, son interprétation est plutôt simple. Le svi étant un *factor*, elle ne fait que déplacer (avec confiance 95%) l’intercept d’un facteur 0.66 ± 0.42 (2 fois la déviation standard) entre les deux populations ($\{\text{svi} = 0\}$, $\{\text{svi} = 1\}$). En particulier, une augmentation soudaine du lpsa chez un patient pourrait alors être associée à une invasion des vésicules séminales par les cellules cancéreuses.

Similairement, si le poids du patient (ou en tout cas le poids de sa prostate) n’a pas changé drastiquement sur un laps de temps, une augmentation du lpsa pourrait aussi être associée à une augmentation du volume de cellules cancéreuses. En effet, en fixant les deux autres prédicteurs comme constant, en prenant la différence entre les données finales et initiales, et en passant à l’exponentielle, on obtient en moyenne : $\text{psa}_f / \text{psa}_i = (\text{cavol}_f / \text{cavol}_i)^{0.53 \pm 0.15}$. Donc si le volume de cancer augmente d’un certain pourcentage, alors le psa, en moyenne, augmentera aussi d’un certain pourcentage. Ainsi, le lpsa semble être un bon indicateur de l’avancée du cancer chez un patient selon notre modèle. De plus, par la Figure 5, lorsque l’on prend en compte toutes les variables autres que lcavol, le graphique montre une relation linéaire entre lpsa et lcavol.

Cependant, notre modèle ne dit pas que c’est un bon indicateur de détection du cancer, et c’est presque sûrement faux. Tout d’abord, notre modèle a été construit à partir de données sur des personnes souffrant du cancer. Il ne peut donc être utilisé que pour faire des prédictions pour des personnes dont on sait qu’elles ont le cancer, au risque de faire de nombreux faux diagnostics. En effet, selon notre modèle, pour un patient sain (i.e. $\text{lcavol} = \log(0.25)$), une petite valeur substituée au lieu de zéro, et $\text{svi} = 0$), on obtient que le lpsa est simplement une fonction de lweight, une constante, et un bruit, ce qui est un modèle trop simple de la réalité. En effet, nous savons que le bph et l’âge sont des facteurs influençant de manière non négligeable le psa (Nadler RB 1995, Collins GN (1993)) chez les personnes saines. Ainsi, chez les personnes souffrant du cancer, notre analyse nous a suggéré que le lpsa est dominé par d’autres effets (liés à la condition du cancer).

Conclusion

Dans ce rapport, nous avons utilisé diverses méthodes de sélection de modèles pour aboutir à un modèle simple pour le lpsa, chez des patients souffrant du cancer de la prostate, à 3 prédicteurs : lcavol, lweight et svi. Nous avons déterminé que les autres prédicteurs ne sont pas significatifs en présence de ceux-ci, de même que pour les termes d’interactions. De plus, il apparaît que chez les personnes souffrant du cancer, un soudain changement du taux de lpsa ne peut, selon notre modèle, presque être attribué uniquement qu’à la progression du cancer.

Bibliographie

Belzile, Leo. 2017. “R-Tutorials for the Linear Models’ Course at Epfl.”

Breiman Leo, Stone Charles J., Friedman Jerome. 1984. *Classification and Regression Trees*. Taylor & Francis.

Collins GN, McKelvie GB, Lee RJ. 1993. “Relationship Between Prostate Specific Antigen, Prostate Volume and Age in the Benign Prostate.” *British Journal of Urology* 71 (4) : 445–50.

Nadler RB, Smith DS, Humphrey PA. 1995. “Effect of Inflammation and Benign Prostatic Hyperplasia on Elevated Serum Prostate Specific Antigen Levels.” *Journal of Urology* 154 (2 Pt 1) : 407–13.

Stamey, Kabalin, T.A., and N. Yang. 1989. “Prostate Specific Antigen in the Diagnosis and Treatment of Adenocarcinoma of the Prostate : II. Radical Prostatectomy Treated Patients.” *Journal of Urology* 141 (5) : 1076–83.

Thibaud, Emeric Rolland Georges. 2017. “Linear Models’ Course at Epfl.”

Wakefield, Jon. 2013. *Bayesian and Frequentist Regression Methods*. Springer.